嘉兴大学实验报告

实验名称：基于气象条件回归校正的北京 PM2.5 污染变化趋势分析（2015—2025）

班级：数经 251　姓名：　　学号：　　成绩：

一、实验目的

细颗粒物（PM2.5）是影响我国城市居民健康的关键环境风险因素，既有研究估计 PM 每升高 10 μg/m³，居民预期寿命约缩短 0.64 年（Chen 等，2013；Ebenstein 等，2017）。2013 年《大气污染防治行动计划》（“大气十条”）与 2018 年《打赢蓝天保卫战三年行动计划》实施以来，北京 PM2.5 年均浓度已由 2015 年的 82.7 μg/m³ 降至 2025 年的 27.4 μg/m³。但污染物浓度由排放强度与气象条件共同决定，风速、湿度、降水都会影响扩散与清除，把“浓度下降”直接等同于“治理有效”并不严谨：若观测期恰好多风多雨，浓度同样会下降。只有把气象贡献从观测序列中分离出来，才能判断改善究竟来自“人努力”还是“天帮忙”。

本实验以北京 2015—2025 年的日度数据为对象，具体目的包括：（1）完成公开空气质量数据与气象再分析数据的获取、清洗与质量控制，掌握多源数据合并方法；（2）通过描述性统计与可视化，刻画 PM2.5 的长期趋势、季节特征与气象关联；（3）建立含月份固定效应与气象变量的对数线性回归模型，估计气象校正后的浓度变化趋势，并对十年降幅作“趋势—气象”归因分解。

实验共使用 35 个国控站点逐小时监测数据（约 995 万个原始单元格）与 ERA5 日度气象数据，全部清洗、统计与绘图均由 Python 完成，代码与数据随报告一并提交，所有结果可完整复现。

二、实验原理和步骤

（一）实验原理：

1. 数据来源与变量。空气质量数据来自“中国空气质量在线监测分析平台”（quotsoft.net）归档的北京市逐日数据文件，每个文件记录当日 24 个整点、35 个国控监测站的 PM2.5、PM10、AQI 等指标；研究区间 2015-01-01 至 2025-12-31 共 4 018 个自然日，实际获取 3 999 个日文件。气象数据来自 Open-Meteo 历史天气接口（底层为 ECMWF

ERA5 再分析资料），取北京城区格点（39.90°N，116.41°E）的日平均气温、日降水量、日最大风速与日平均相对湿度，共 4 018 天且无缺失。主要变量定义见表 1。

表 1 主要变量定义与说明

变量	单位	说明
PM2.5	μg/m³	全市 35 个国控站日均值（先按小时、再按日两级聚合）
PM10	μg/m³	同上
AQI	—	同上（日均值由逐小时 AQI 平均得到）
PM2.5/PM10	—	细颗粒物占可吸入颗粒物的比例
气温	℃	日平均气温（ERA5）
风速	km/h	日最大风速（ERA5，10 m 高度）
相对湿度	%	日平均相对湿度（ERA5）
降水	mm	日累计降水量（ERA5）
采暖季	0/1	11 月 15 日至次年 3 月 15 日取 1，否则取 0
年份趋势	年	年份减 2015

2. 数据清洗原理。原始数据存在源站缺档、仪器空值与异常值、站点小时覆盖不均三类质量问题。清洗按“文件—单元格—小时—日”四级流程进行：单元格层面剔除空值、负值与超物理上限值（PM2.5 大于 1 000、PM10 大于 2 000、AQI 大于 500）；小时层面要求有效站点数不少于 60%（21/35）才计算城市小时均值，避免少数站点代表全城；日层面要求有效小时数不少于 18 个（75%）才计算日均值；源站缺失日不作插值，以保留重污染过程的方差特征。

3. 模型原理。为分离长期趋势与气象波动，建立对数线性模型：

$$ln(PM2.5_t) = \alpha + \beta \cdot Year_t + \gamma' \cdot W_t + \Sigma \delta_m \cdot Month_m + \varepsilon_t$$

其中 Year 为年份减 2015，W 为四个气象变量，Month 为月份虚拟变量，用以吸收固定的季节循环；被解释变量取对数以缓解浓度分布的右偏与异方差。考虑到日度序列的自相关与异方差，标准误采用 Newey-West HAC 估计（滞后 14 期，约两周）。在此基础上，以 2015 年气象条件为基准构造“气象校正反事实”序列：校正浓度 = 年均浓度 ÷ exp(Σγk·(Wk,当年 − Wk,2015))，并将 2015—2025 年的对数总变化分解为气象部分与趋势部分，从而量化“天帮忙”对十年降幅的贡献。

（二）实验步骤：

① 数据获取：从 quotsoft.net 下载 3 999 个逐日站点文件，从 Open-Meteo API 获取同期

日度气象数据；

② 文件完整性检查：逐一核对 4 018 个自然日的文件存在性与大小，记录 19 个缺失日；

③ 单元格有效性清洗：在约 995 万个原始单元格中，剔除空值 866 466 个（8.70%）、负值 0 个、超物理上限值 1 300 个（0.013%）；

④ 小时聚合：对每个“日期×指标×整点”，有效站点数达 60% 方计算城市小时均值，287 928 个小时—指标组合中剔除 18 565 个（6.45%）；

⑤ 日聚合：当日有效小时数达 18 个方计算日均值，剔除 63 天，得到 3 936 个有效日样本（覆盖率 97.96%）；

⑥ 气象合并与派生变量：按日期左连接气象数据，构造对数浓度、PM2.5/PM10 比值、采暖季虚拟变量与年份趋势项；

⑦ 描述性统计与可视化：计算主要变量分布统计与年度汇总（表 3、表 4），绘制时间序列、季节分布、气象关联等图（图 1—图 4）；

⑧ 回归与归因：估计模型（1）（2），作气象校正反事实与对数变化分解（表 5、图 5），并与官方公报数据交叉核验。

以上步骤全部由 Python（pandas、statsmodels、matplotlib）实现，完整代码见随报告提交的 Jupyter Notebook《北京 PM2.5 污染趋势分析.ipynb》，顺序执行即可复现本报告的全部数字、表格与图。随报告提交的文件包括：原始站点—小时数据（raw_beijing_site_hour_2015_2025.csv.gz）、气象日度数据（weather_beijing_daily_2015_2025.csv）、清洗后日度数据及全部统计输出（output/ 目录）、图（figures/目录）。

三、实验内容及数据记录

1. 数据清洗结果（数据记录）

表 2 汇总了清洗各环节的处理规则与样本量变化。四类问题中共识别并处理：源站缺失 19 天、空值 86.6 万个、超限值 1 300 个、站点覆盖不足的小时 18 565 个、有效小时不足的 63 天，最终保留 3 936 个有效日样本，占全部自然日的 97.96%；样本内日均有效小时 23.66 个，站点数恒为 35 个，未引入任何插值。

表 2 数据清洗流程与样本量

步骤	处理规则	结果
1 文件完整性	应有 4 018 个日文件，逐一检查	实得 3 999 个，缺失 19 天（0.47%）
2 单元格有效性	剔除空值、负值与超物理上限值	共 9 954 770 个单元格；空值 866 466（8.70%）；负值 0；超限 1 300（0.013%）
3 小时聚合	单小时有效站点不少于 60%（21/35）	287 928 个小时—指标组合，剔除 18 565（6.45%）
4 日聚合	单日有效小时不少于 18（75%）	剔除 63 天（1.58%）
5 气象合并	按日期左连接 ERA5 数据	3 999 天全部匹配
6 派生变量	构造对数、比值、采暖季与趋势项	最终有效日样本 3 936 天（97.96%）

关键规则说明：缺失日不作插值，19 个缺失日呈块状分布（2017-05-19 至 05-27 等），判断为源站归档缺口而非随机缺测，插值会人为压低方差、平滑极值；空值主要集中在 2015—2016 年 PM10 的部分站点，这也是 PM10 有效样本（3 127 天）明显少于 PM2.5（3 936 天）的原因；2017 年因站点覆盖不足损失 30 天，该年日均有效小时仅 22.8 个，低于其他年份的 23.5—24.0 个。

数据质量核验：本文计算的 2015 年 PM2.5 年均值为 82.7 μg/m³，官方公报值为 80.6 μg/m³，相对偏差约 2.6%；按 PM2.5 日均值大于 150 μg/m³ 计得的 2015 年重污染天数为 48 天，官方口径为 46 天，量级一致；PM2.5 与 PM10 日序列相关系数 0.82，与 AQI 相关 0.92，符合污染物同源、同过程的常识。三项核对表明清洗后的数据在水平、频数与结构上均与官方口径基本吻合。

2. 描述性统计

表 3 报告清洗后主要变量的分布特征。PM2.5 日均浓度均值 46.1 μg/m³，中位数 31.5 μg/m³，标准差 45.9 μg/m³，均值约为中位数的 1.46 倍，分布明显右偏；最小值 1.6 μg/m³，最大值 439.8 μg/m³，少数重污染日对均值贡献很大——这也是后文回归采用对数形式的原因。PM2.5/PM10 比值均值 0.50，其中采暖季 0.53 高于非采暖季的 0.48，说明采暖期细颗粒占比更高。气象变量方面，日均气温 13.2 ℃、日最大风速 16.8 km/h、相对湿度 51.9%；降水中位数为 0、均值 1.74 mm，呈强右偏，符合北京“少雨、集中”的降水特征。

表 3 清洗后主要变量的描述性统计

变量	样本量	均值	标准差	最小值	P25	中位数	P75	P95	最大值
PM2.5 日均浓度 (μg/m³)	3,936	46.1	45.9	1.6	16.5	31.5	58.2	132.6	439.8
PM10 日均浓度 (μg/m³)	3,127	70.5	54.5	4.3	35.3	56.9	89.9	162.4	764.3
AQI 日均值	3,924	74.9	52.7	11.6	40.2	60.4	89.8	178.4	459.1
PM2.5/PM10 比值	3,127	0.5	0.2	0.1	0.4	0.5	0.6	0.8	1.0
日均气温 (℃)	3,999	13.2	11.3	-14.5	1.9	14.3	23.8	28.5	34.0
日最大风速 (km/h)	3,999	16.8	6.9	4.7	11.3	15.5	20.9	29.8	54.3
日均相对湿度 (%)	3,999	51.9	20.7	7.0	35.0	50.0	70.0	85.0	97.0
日降水量 (mm)	3,999	1.7	7.0	0.0	0.0	0.0	0.1	10.1	180.2

注：样本期为 2015-01-01 至 2025-12-31；浓度单位为 μg/m³，气温为 ℃，风速为 km/h，相对湿度为 %，降水为 mm。

3. 年度变化

表 4 与图 2 给出逐年结果。2015—2025 年，PM2.5 年均浓度由 82.7 μg/m³ 降至 27.4 μg/m³，累计下降 66.8%，几何年均降幅约 10.5%；重污染天数（日均值大于 150 μg/m³）由 48 天降至 2 天；按日均值不超过 75 μg/m³（环境空气质量二级标准）计的达标率由 59.0% 升至 95.3%；95 分位浓度由 237 μg/m³ 降至 72 μg/m³（-69.6%），说明改善不仅体现在平均水平，也体现在极端污染过程上。值得注意的是，下降并非单调：2022 年降至 30.4 μg/m³ 的阶段低点后，2023 年反弹至 34.9 μg/m³（较 2022 年上升 14.8%），2024—2025 年重新下降。年度均值受气象年景影响明显，仅凭“一年高一年低”判断治理效果容易误读。

表 4　北京 PM2.5 年均浓度与污染天数的年度变化

年份	有效天数	年均浓度 (μg/m³)	中位数 (μg/m³)	P95 (μg/m³)	重污染天数 (>150 μg/m³)	达标率 (≤75 μg/m³, %)
2015	361	82.7	60.5	237	48	59.0
2016	358	73.8	58.7	200	38	62.3
2017	325	60.3	43.3	161	20	75.7
2018	361	52.6	44.0	137	13	79.2
2019	357	43.0	34.6	111	4	86.6
2020	361	38.5	29.8	101	8	90.0
2021	360	34.4	22.3	116	6	89.4
2022	365	30.4	22.0	90	2	92.1
2023	363	34.9	25.4	111	4	88.4
2024	364	31.4	25.2	81	1	94.0
2025	361	27.4	20.8	72	2	95.3

注：重污染天数按 PM2.5 日均值大于 150 μg/m³ 统计；达标率按日均值不超过 75 μg/m³ 统计。

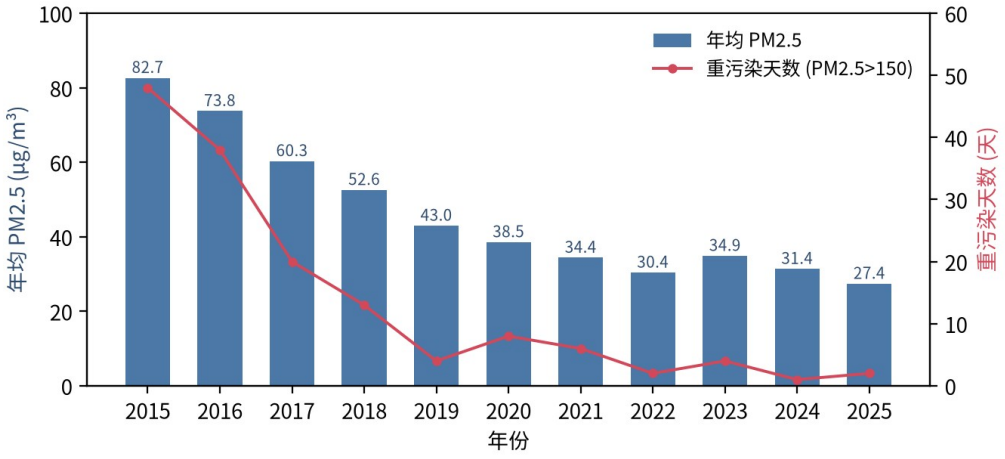


图 2　北京 PM2.5 年均浓度与重污染天数的年度变化（2015—2025）

4. 时间序列与季节特征

图 1 显示三个特征。第一，趋势性下降：30 日滑动平均由 2015 年初的约 110 μg/m³ 降至 2025 年的 30 μg/m³ 左右；第二，强季节性：每年 11 月至次年 3 月出现峰值，与采暖期高度重合（图中阴影）；第三，尖峰衰减：2015—2017 年冬季多次出现 300—440 μg/m³ 的日值，而 2022—2025 年的日最大值仅为 170.6 μg/m³，极端污染过程被显著压缩。

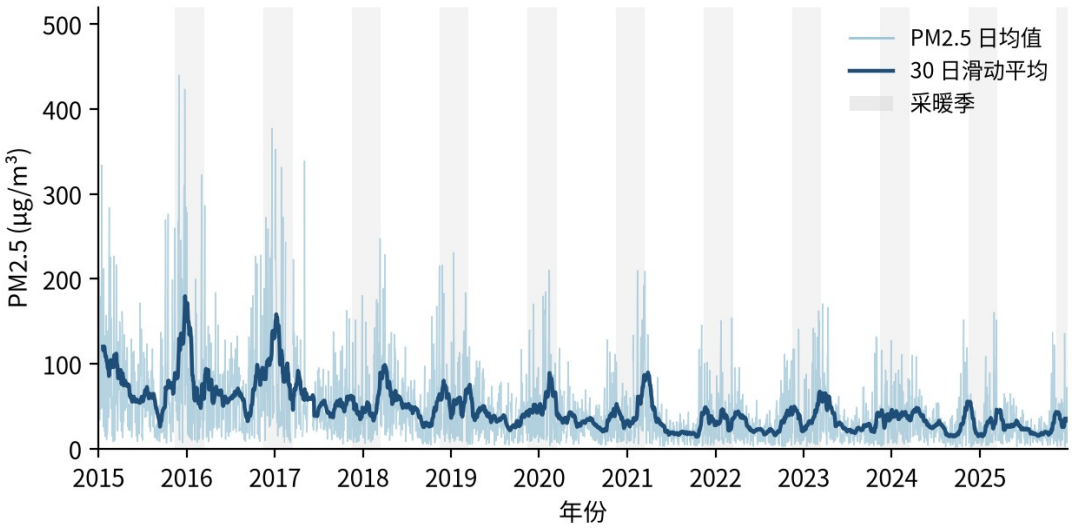


图 1 2015—2025 年北京 PM2.5 日度序列与 30 日滑动平均（阴影为采暖季）

图 3 的月度箱线图进一步刻画季节分布：1 月均值最高（58.0 μg/m³），8 月最低（27.7 μg/m³），相差约 2.1 倍；采暖季均值 57.0 μg/m³，比非采暖季的 40.8 μg/m³ 高约 40%。非采暖季平均浓度仍在 40 μg/m³ 左右，说明采暖排放只是季节性的一部分，工业、交通与区域传输在全年均有贡献；采暖季月份的箱体更长、上须更高，说明不仅平均水平更高，污染过程的波动也更大。

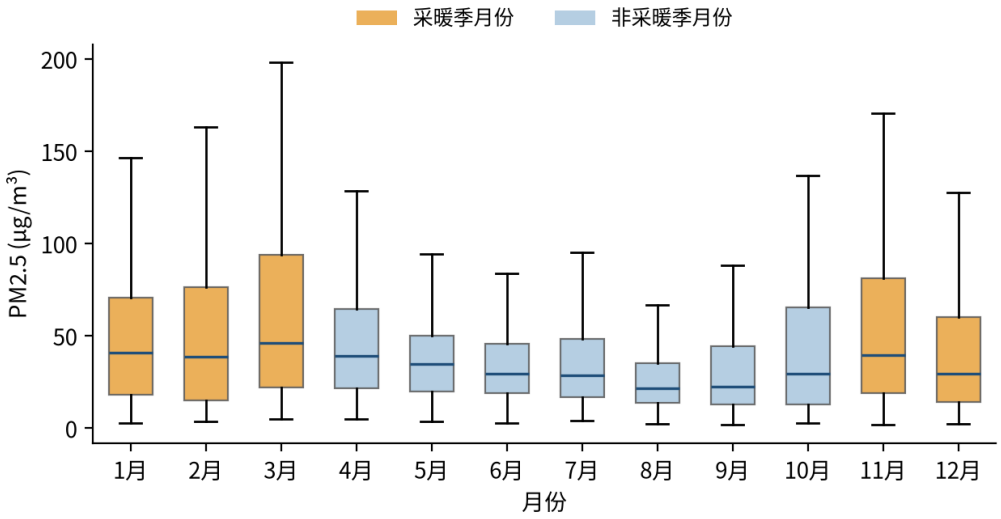


图 3 北京 PM2.5 浓度的月度分布（箱线图）

5. 气象因子与 PM2.5 的关系

图 4 给出风速、相对湿度与 PM2.5 的散点及十分位分箱均值。风速与 PM2.5 的相关系数为 -0.25：风速低于 10 km/h 时 PM2.5 平均约 70 μg/m³，高于 20 km/h 时降至约 32

μg/m³，呈明显的阈值式下降，符合“风速增大—水平扩散增强—浓度降低”的物理机制。相对湿度与 PM2.5 的相关系数为 +0.25：湿度超过 60% 后分箱均值升至约 60 μg/m³，与颗粒物吸湿增长、二次气溶胶生成增强有关。气温与降水的简单相关系数分别为 -0.14 和 -0.08，均较弱——气温的负相关很大程度上是季节混杂的产物，降水的影响则因北京降水稀少而在日度相关中难以体现。四个变量的相关系数绝对值均小于 0.26，说明必须在控制季节与其他气象因素之后进行多变量回归，才能可靠地刻画各因子的作用。

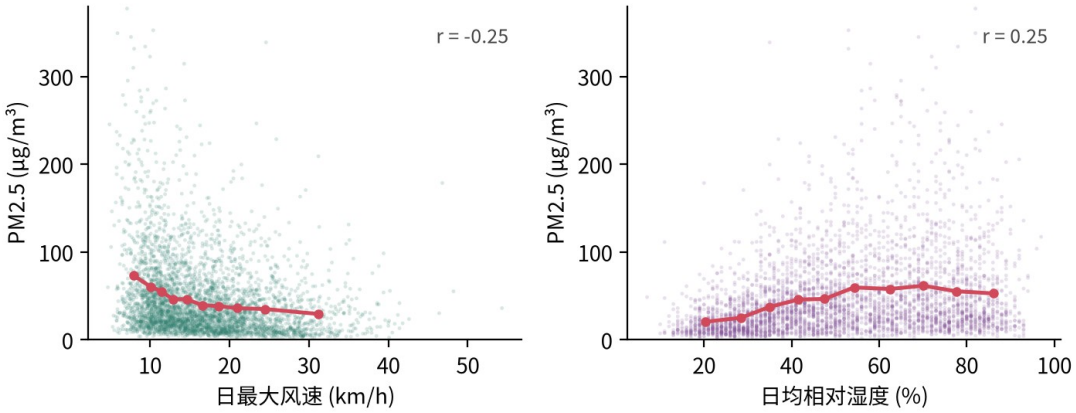


图 4 风速、相对湿度与 PM2.5 的关系（红点为十分位分箱均值）

6. 回归结果与气象校正

表 5 报告两个模型的估计结果。模型（1）仅含年份趋势与月份固定效应，趋势项为 -0.1078（对应年均下降约 10.2%），R^2 为 0.191；模型（2）加入四个气象变量后，趋势项为 -0.1117（$p<0.001$，对应年均下降约 10.6%），R^2 升至 0.562。趋势系数的绝对值不降反升，说明气象变量并没有“吸收”长期下降，观测到的改善不能由同期气象条件解释。四个气象变量均在 1% 水平显著：风速每增加 1 km/h，PM2.5 约下降 1.6%；降水每增加 1 mm 约下降 1.5%；相对湿度每增加 1 个百分点约上升 2.7%；气温每升高 1 ℃ 约上升 7.0%——气温的正系数并非因果效应，而是控制月份后“同月内”的天气扰动：冬季升温常伴随暖平流、逆温与湿度增加，反而不利于扩散。

表 5 回归结果（被解释变量：ln PM2.5）

变量	模型（1）	模型（2）
年份趋势	-0.1078*** (0.0065)	-0.1117*** (0.0052)
风速	—	-0.0162*** (0.0024)
气温	—	0.0698*** (0.0044)
相对湿度	—	0.0273*** (0.0010)
降水	—	-0.0155*** (0.0033)
月份固定效应	控制	控制
观测值	3,936	3,936
R^2	0.191	0.562

注：括号内为 Newey-West HAC 标准误（滞后 14 期）；***、**、* 分别表示 p<0.01、p<0.05、p<0.1。

以 2015 年为基期作对数分解：2015—2025 年 PM2.5 实际下降 66.8%，对数总变化 -1.104，其中气象条件变化贡献 -0.047（占 4.3%），扣除气象后的趋势项贡献 -1.057（占 95.7%）。“天帮忙”只能解释很小一部分，长期下降主要由减排与结构调整等趋势性因素驱动。图 5 将这一结果可视化：以 2015 年气象条件为基准校正后，2016—2020 年校正曲线明显高于实际曲线（2019 年高出约 31%，56.4 对 43.0 μg/m³），说明这几年气象偏有利、放大了表观改善；2022—2023 年校正值高于观测值，说明这两年气象偏不利；尽管年际波动明显，两条曲线的长期下行方向一致，气象影响的是“波动”而非“趋势”。

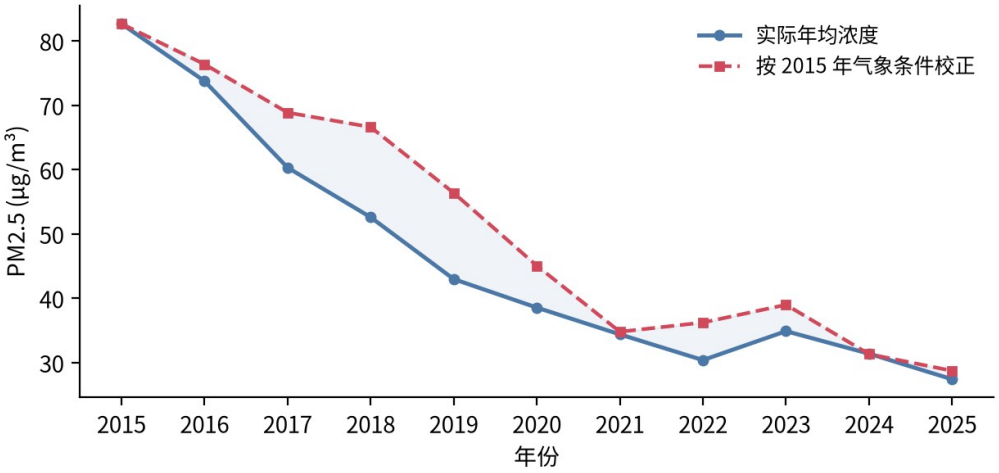


图 5 实际年均浓度与按 2015 年气象条件校正的浓度

四、实验结论及体会

（一）实验结论：

（1）浓度大幅下降。2015—2025 年北京 PM2.5 年均浓度由 82.7 μg/m³ 降至 27.4 μg/m³，累计下降 66.8%，几何年均降幅约 10.5%；重污染天数由 48 天降至 2 天，达标率由 59.0% 升至 95.3%，95 分位浓度下降 69.6%，改善同时体现在平均水平与极端污染过程上。

（2）显著的“冬高夏低”季节性。1 月均值约为 8 月的 2.1 倍，采暖季均值比非采暖季高约 40%；但非采暖季仍有约 40 μg/m³ 的背景浓度，说明采暖排放并非季节性的全部来源。

（3）气象因子作用显著但解释力有限。风速与降水抑制浓度、相对湿度促进浓度，控制季节后各系数均在 1% 水平显著；但单变量相关系数绝对值均小于 0.26，PM2.5 受多因素共同作用，不能依据简单相关作因果判断。

（4）改善主要来自趋势项而非气象。控制月份与气象条件后，趋势项仍对应年均下降约 10.6%（$p<0.001$），模型 R^2 由 0.19 提升至 0.56；十年降幅中约 95.7% 归于趋势项，气象仅占 4.3%，即观测到的改善主要不是“天帮忙”，而更可能来自持续的减排与结构调整。

（5）数据清洗是结论可靠的前提。19 个缺失日、8.70% 的空值、1 300 个超限值和 63 个覆盖不足日被逐一识别并处理，最终样本覆盖 97.96% 且与官方年度值相互印证；若不设站点与小时门槛、不剔除异常值，少数站点的缺测或故障可能主导日均值，进而扭曲趋势估计。

需要说明的是，本文属于观测数据的回归校正，只能控制可观测的气象混杂，无法排除区域传输、排放逐日变化等未观测因素，因此不作严格的因果解释；气象再分析资料与

站点观测的空间尺度差异也可能低估局地静稳条件的作用，这些都是后续可以改进的方向。

（二）实验体会：

这次实验最直接的体会是：数据清洗占去了整个分析八成以上的工作量，也决定了结论可靠性的上限。约 995 万个原始单元格中隐藏着 8.70% 的空值、1 300 个超限值和源站 19 天的归档缺口；如果没有“60% 站点”与“18 小时”两道门槛，个别站点的故障读数就足以扭曲日均值乃至年度趋势。与官方公报的交叉核验（年均值偏差 2.6%、重污染天数 48 对 46 天）让我第一次直观感受到“清洗后口径吻合”给结论带来的底气。

方法上的收获是理解了描述性统计与回归分析的分工。箱线图和分箱散点揭示了“冬高夏低”“风大浓度低、湿大浓度高”等典型事实，但气温的简单相关系数（-0.14）其实是季节混杂的产物，只有在回归中控制月份固定效应后，系数才变为 +0.070 并得到合理解释。这提醒我：相关不等于因果，多变量控制是解读环境数据的基本功。

“气象校正”是本次实验最有意思的部分。把气象条件固定在 2015 年后，2019 年的校正浓度比实际观测高 31%，说明当年“天帮忙”夸大了表观改善；而十年降幅的 95.7% 由趋势项解释，说明北京的蓝天主要是“人努力”的结果。此外，用 Jupyter Notebook 把“下载—清洗—统计—建模—绘图”全流程固化下来，让报告中的每一个数字都可一键复现，也让我体会到可复现性对数据分析工作的价值。